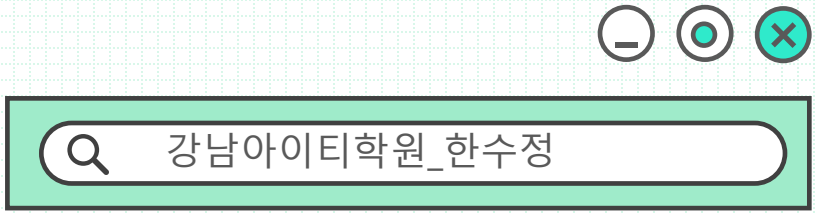

Movie ‘CATS’ Analysis
- WebCrawling & ManchineLearning -

CONTENTS

Step 1. Task Setting

Step 2. Data Collecting – WebCrawling

Step 3. Data Preparation

Step 4. Model Training

Step 5. Model Qualification

Step 6. Review Prediction

As a Result ...

Step 1. Task Setting

Step 1. Task Setting

- Background : Want to know the rating of the movie 'Cats'
- Purpose : Analyzing Movie Rating using Audience Evaluation
- Data used for Collecting : Naver Movie – Cats
- Collecting Method : Web Scraping by using Jupyter Notebook
- Model used for Analysis : LSTM model
- Analysis method :

데이터 정제 → 토큰화 → 모델 형성 → 모델 적용

Step 2. Data Collecting – WebCrawling

Step 2. Data Collecting - WebCrawling

① Model used for Web Scraping

```
from bs4 import BeautifulSoup # 리뷰할 내용 긁어오기
from selenium import webdriver # 웹페이지 열기
import time # 시간(현재/멈춤 등)과 관련된 코드 실행
import math # 수학적 계산 실행
import os # 파일 생성/열기/지정
import pandas as pd  # 데이터 조작/분석
import numpy as np # 수치계산
```

② Open Web Page

```
# 입력 받기
what_movie = input("영화 제목을 입력하세요. ")

# 네이버 영화 창 열기
from selenium import webdriver
chrome_path = 'E:₩₩py_temp₩₩WebCrawling₩₩chromedriver.exe'
driver = webdriver.Chrome(chrome_path)
url = 'https://movie.naver.com/'
driver.get(url)
driver.maximize_window()
import time
time.sleep(2)

# 쿠키 삭제하기
driver.delete_all_cookies()
time.sleep(1)
```

Input : 영화 'Cats' 입력하기

"쿠키 삭제" : 간혹 사이트에서 자동 크롤링이 감지되면 접근 차단이 되기에 수시로 지우기

Step 2. Data Collecting - WebCrawling

③ Search movie 'Cats'

```
search_bar = driver.find_element_by_id('ipt_tx_srch')
search_bar.click()
search_bar.send_keys(what_movie)
search_bar.send_keys("₩n")
movie_click = driver.find_element_by_xpath('//*[@id="old_content"]/ul[2]/li[1]/dl/dt/a')
movie_click.click()
movie_grade = driver.find_element_by_link_text('평점')
movie_grade.click()
```

④ Enter to the audience rating page and Check the number of reviewers

```
full_html = driver.page_source
soup = BeautifulSoup(full_html,'html.parser')
f_review = soup.find('iframe',id="pointAfterListIframe")['src']
driver.get(url+f_review)
review_html = driver.page_source
frame_soup = BeautifulSoup(review_html,'html.parser')
total_r = frame_soup.find('body').find('div',class_='score_total')
total_r = total_r.find('strong','total').find('em').text.strip()
total_r = total_r.replace(",","")
total_r = int(total_r)
cnt = total_r
```

"Inner_html" : 이는 JavaScript를 이용하여 html을 넣은 구조로, iframe의 src(link)를 찾아 해당 페이지로 다시 들어가야 한다.
* 주의 : 'src'는 현재 url 이후의 link를 표기하기 때문에 #document의 주소는 'url+src'이다.

Step 2. Data Collecting - WebCrawling

⑤ Make a function of Web Scraping

```
def get():
    os.chdir(folder_path)

    f.write("-------------------------------------------------------------------------------"+"₩n"+"₩n")
    print("-" *70)
    print()
    each_movie = r_list[x]

    number.append(count)
    print("%s번째 리뷰" %count)
    f.write("%s번째 리뷰 ₩n" %count)


    some_review = each_movie.find('div','score_reple')
    n_and_d = some_review.find('dl').find_all('em')
    try:
        name = n_and_d[0].find('span').text.strip()
        n_review.append(name)
    except:
        n_review.append("-")
        print("1. Reviewer: -")
        f.write("1. Reviewer: - ₩n")
    else:
        print("1. Reviewer:",name)
        f.write("1. Reviewer: %s ₩n" %name)

    try:
        date = n_and_d[1].text.strip()
        d_review.append(date)
    except:
        d_review.append("-")
        print("2. Date: -")
        f.write("2. Date: - ₩n")
    else:
        print("2. Date:",date)
        f.write("2. Date: %s ₩n" %date)
```

사용자 이름(Reviewer)과 날짜(Date)는 모두 'em' 태그로 지정되어 있기 때문에, 모든 태그를 find_all을 이용하여 리스트로 만든 후 각각 지목해야 한다.

```
try:
    star = each_movie.find('div','star_score').find('em').text.strip()
    s_review.append(star)
except:
    s_review.append("-")
    print("3. Reviewer Rating: -/10")
    f.write("3. Reviewer Rating: -/10 ₩n")
else:
    print("3. Reviewer Rating: %s/10" %star)
    f.write("3. Reviewer Rating: %s/10 ₩n" %star)
```

ⓐ 관람객 평가

```
<p>
  <span class="ico_viewer">관람객</span>
  <!-- 스포일러 컨텐츠로 처리되는지 여부 -->
  <span id="_filtered_ment_5">
    " 배우들의 노래와 아름다운 춤 덕분에 뮤지컬 캣츠가 좀더 친근하게 다가왔고, 오랜만에 문화 충전한 것 같아 대만족이었습니다. "
  </span>
</p>
```

```
try:
    contents = some_review.find('p').find_all('span')
    contents = contents[1].text.strip()
    r_review.append(contents)
except:
    contents = some_review.find('p').find('span').text.strip()
    r_review.append(contents)
    print("4. Review: %s" %contents)
    f.write("4. Review: %s ₩n" %contents)
else:
    print("4. Review:",contents)
    f.write("4. Review: %s ₩n" %contents)
```

ⓑ 네티즌 평가

```
<p>
  <!-- 스포일러 컨텐츠로 처리되는지 여부 -->
  <span id="_filtered_ment_6">
    " 이거 별5개 준거 분명히 알바다. 전짜 리뷰를 보고 싶다면 전문 외국 리뷰를봐라. 그럼 당신의 지갑과 눈은 안전할테니깐 "
  </span>
</p>
```

```
try:
    like = each_movie.find('a','_sympathyButton').find('strong').text.strip()
    l_review.append(like)
except:
    l_review.append("-")
    print("5. Like: -")
    f.write("5. Like: - ₩n")
else:
    print("5. Like:",like)
    f.write("5. Like: %s ₩n" %like)

try:
    dislike = each_movie.find('a','_notSympathyButton').find('strong').text.strip()
    dl_review.append(dislike)
except:
    dl_review.append("-")
    print("6. Dislike: -")
    f.write("6. Dislike: - ₩n")
else:
    print("6. Dislike:",dislike)
    f.write("6. Dislike: %s ₩n" %dislike)
print()
print('-'*70)
f.write("₩n")
```

관람객 평가와 네티즌 평가는 span의 개수가 다르다. Id 혹은 Class의 이름이 리뷰마다 다르기 때문에 span 개수의 차이를 이용해야 한다. 관람객 평가의 경우 평가 내용이 2개의 span 중 2번째에 있기 때문에 모든 span을 find_all을 이용하여 리스트로 만든 후 두번째 리스트를 지목해야 한다. 네티즌 평가의 경우 span이 하나이기 때문에 관람객 평가 시도 시 Error가 발생한다. 이를 이용하면 위치가 다른 두 평가를 모두 긁어 올 수 있다.

Step 2. Data Collecting - WebCrawling

⑥ Web Scraping

```
f = open(text_name, 'a',encoding='UTF-8') # 메모장 열기
count = 1
page = int(np.ceil(cnt/10)) # 긁어야할 데이터의 페이지수
last_cnt = int(cnt-(page*10-10)) # 마지막 페이지에서 긁어야 할 데이터의 개수

for i in range(1,page+1):
    driver.delete_all_cookies()
    time.sleep(0.5)

    # 만일, 1000페이지 이상일 때 1000단위 ',' 붙이기
    if i >= 1000:
        i = format(i, ',')
    else:
        pass
    page = driver.find_element_by_link_text('%s' %i)
    page.click()
    time.sleep(0.5)
    print("%s 페이지 추출을 시작합니다." %i)
    page = int(np.ceil(cnt/10))

    # 데이터 긁어오기
    if i == page: # 마지막 페이지 내용 긁어오기
        review_html = driver.page_source
        soup = BeautifulSoup(review_html,'html.parser')
        main = soup.find('div','score_result').find('ul')
        r_list = main.find_all('li')
        for x in range(0,last_cnt):
            get()
            count += 1
    else:
        review_html = driver.page_source
        soup = BeautifulSoup(review_html,'html.parser')
        main = soup.find('div','score_result').find('ul')
        r_list = main.find_all('li')
        for x in range(0,10):
            get()
            count += 1
```

1000 단위 이상 페이지부터는 ' , '가 들어가야 하기 때문에 if문을 이용하여 콤마(,)를 삽입한다.

Step 2. Data Collecting - WebCrawling

⑦ Save data in txt/csv/xlsx

```
os.chdir(folder_path) # 파일을 저장할 경로 지정

# txt 파일에 크롤링 요약 정보 저장하기
import sys
orig_stdout = sys.stdout
f = open(text_name,'a',encoding='UTF-8')
sys.stdout = f
sys.stdout = orig_stdout
f.close( )

# 데이터 프레임 형태로 리스트 취합하기
movie_frame = pd.DataFrame()
movie_frame['Review Number']=pd.Series(number)
movie_frame['Reviewer']=pd.Series(n_review)
movie_frame['Date']=pd.Series(d_review)
movie_frame['Reviewer Rating']=pd.Series(s_review)
movie_frame['Review']=pd.Series(r_review)
movie_frame['Like']=pd.Series(l_review)
movie_frame['Dislike']=pd.Series(dl_review)

# csv 형태로 저장하기
movie_frame.to_csv(csv_name,encoding="utf-8-sig",index=False)

# 엑셀 형태로 저장하기
movie_frame.to_excel(xlsx_name,encoding='utf-8-sig',index=False)
```

Result

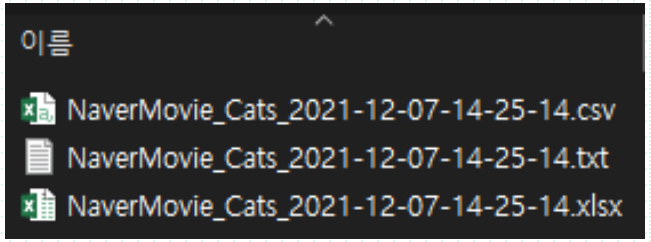

txt/csv/xlsx 파일 각각 생성

```
    raise IllegalCharacterError
openpyxl.utils.exceptions.IllegalCharacterError
```

'IllegalCharacterError' 발생 → cmd에서 'pip install xlsx writer' 실행

Step 3. Data Preparation

Step 3. Data Preparation

① Training-Test Data Characteristics

```
id      document        label
9976970 아 더빙.. 진짜 짜증나네요 목소리       0
3819312 흠...포스터보고 초딩영화줄....오버연기조차 가볍지 않구나       1
10265843        너무재밋었다그래서보는것을추천한다      0
9045019 교도소 이야기구먼 ..솔직히 재미는 없다..평점 조정       0
6483659 사이몬페그의 익살스런 연기가 돋보였던 영화!스파이더맨에서 늙어보이기만 했던 커스틴 던스트가 너무나도 이뻐보였다 1
5403919 막 걸음마 뗀 3세부터 초등학교 1학년생인 8살용영화.ㅋㅋㅋ...별반개도 아까움.     0
7797314 원작의 긴장감을 제대로 살려내지못했다.  0
9443947 별 반개도 아깝다 욕나온다 이응경 길용우 연기생활이몇년인지..정말 발로해도 그것보단 낫겠다 납치.감금만반복반복..이드라마는 가족도없다
7156791 액션이 없는데도 재미 있는 몇안되는 영화 1
5912145 왜케 평점이 낮은건데? 꽤 볼만한데.. 헐리우드식 화려함에만 너무 길들여져 있나?   1
9008700 강인피니트가짱이다.진짜짱이다♥ 1
10217543        볼때마다 눈물나서 죽겠다90년대의 향수자극!!허진호는 감성절제멜로의 달인이다~    1
5957425 울면서 손들고 횡단보도 건널때 뛰쳐나올뻔 이범수 연기 드럽게못해 0
8628627 담백하고 깔끔해서 좋다. 신문기사로만 보다 보면 자꾸 잊어버린다. 그들도 사람이었다는 것을.       1
9864035 취향은 존중한다지만 진짜 내생에 극장에서 본 영화중 가장 노잼 노감동임 스토리도 어거지고 감동도 어거지   0
6852435 ㄱ냥 매번 긴장되고 재밋음ㅠㅠ   1
9143163 참 사랑을 옷긴게 바스코가 이기면 락스코라고 까고바비가 이기면 아이돌이라고 깐다.그냥 까고싶어서 안달난것처럼 보인다     1
4891476 굿바이 레닌 표절인것은 이해하는데 왜 뒤로 갈수록 재미없어지냐   0
7465483 이건 정말 깨알 캐스팅과 질퍽하지않은 산뜻한 내용구성이 잘 버무러진 깨알일드!!♥ 1
3989148 약탈자를 위한 변명, 이라. 저놈들은 착한놈들 절대 아닌걸요.      1
4581211 나름 심오한 뜻도 있는 듯. 그냥 학생이 선생과 놀아나는 영화는 절대 아님  1
2718894 보면서 웃지 않는 건 불가능하다  1
9705777 재미없다 지루하고. 같은 음식 영화인데도 바베트의 만찬하고 넘 차이남....바베트의 만찬은 이야기도 있고 음식 보는재미도 있는데 ; 이건 불
471131  절대 평범한 영화가 아닌 수작이라는걸 말씀드립니다.      1
8480268 주제는 좋은데 중반부터 지루하다 0
4254115 다 짤랐을꺼야. 그래서 납득할 수 없었던거야.. 그럴꺼야.. 꼭 그랬던걸꺼야..       0
7295746 kl2g 고추를 털어버려야 할텐데   1
5457633 카밀라벨 발연기 0
6091784 재밋는뎅        1
8322926 센스있는 연출력..탁월한 캐스팅..90년대의 향수.. 그래서 9점..     1
6331922 엄포스의 위력을 다시 한번 깨닫게 해준 적.남 꽃검사님도 연기 정말 좋았어요! 완전 명품드라마!     1
9005897 졸쓰레기 진부하고말도안됌ㅋㅋ 아..시간아까워     0
164908  재밌는데 별점이 왜이리 낮은고   1
9671124 1%라도 기대했던 내가 죄인입니다 죄인입니다....  0
5712231 아직도 이 드라마는 내인생의 최고!       1
4726746 패션에 대한 열정! 안나 윈투어!  1
7203432 키이라 나이틀리가 연기하고자 했던건 대체 정신장애일까 틱장애일까        0
112724  허허...원작가 정신나간 유형이라... 재미있겠네요!        1
1105872 포스터는 있어보이는데 관객은 114명이네  0
4805788 이 영화가 왜 이렇게 저평가 받는지 모르겠다       1
9336496 단순하면서 은은한 매력의 영화   1
9994900 '다 알바생인가 내용도 없고 무서운거도 없고 옷긴거도 하나도 없음 완전 별싱거운 영화.ㅇ.ㅇ내ㅇ시간 넘 아까움 . . . 완전 낚임       0
6760577 오게두어라! 서리한이 긂주렸다!  1
3440864 정말 맘에 들어요. 그래서 또 보고싶은데 또 보는 방법이 없네? >.. ㅜㅡ    1
8548510 윤제문이라는 멋진 배우를 발견하게 됐어요. 소소한 일탈이 잔잔한 미소를 머금게 합니다. 음악은 조금 아쉽네요ㅠㅠ 8점 주고 싶은데 평점 올
7719892 평점에속지마시길시간낭비 돈낭비임        0
```

```
RangeIndex: 50000 entries, 0 to 49999
Data columns (total 3 columns):
 #   Column    Non-Null Count  Dtype
---  ------    --------------  -----
 0   id        50000 non-null  int64
 1   document  49997 non-null  object
 2   label     50000 non-null  int64
dtypes: int64(2), object(1)
memory usage: 1.1+ MB
```

ⓐ Document : 리뷰 데이터 정제 → 토큰화 → 모델 적용

ⓑ Label : 부정 = '0' / 긍정 = '1'

Step 3. Data Preparation

② Data Preprocessing

```
test_data.drop_duplicates(subset = ['document'], inplace=True) # document 열에서 중복인 내용이 있다면 중복 제거
test_data['document'] = test_data['document'].str.replace("[^ㄱ-ㅎㅏ-ㅣ가-힣 ]","") # 정규 표현식 수행
test_data['document'] = test_data['document'].str.replace('^ +', "") # 공백은 empty 값으로 변경
test_data['document'].replace('', np.nan, inplace=True) # 공백은 Null 값으로 변경
test_data = test_data.dropna(how='any') # Null 값 제거
```

ⓐ 중복 샘플 제거

ⓑ 정규 표현식 수행 : 한글과 공백을 제외한 모두 제거 → 알파벳의 경우, resub(r'[^a-z A-Z]','',text) 사용

ⓒ 공백을 Null 값으로 변경 : 영어/숫자/특수문자의 경우, 정규 표현식을 수행하면 빈 값으로 되기에 Null 값으로 변경

ⓓ Null 값 샘플 제거 : Null 값 샘플들은 아무런 의미가 없는 데이터기에 모두 제거

데이터 개수	전처리 전	전처리 후
train_data	150,000	145,393
test_data	50,000	48,852

Step 3. Data Preparation

③ Tokenization

ⓐ 불용어 지정 : 한국어의 조사, 접속사 등 의미 없는 글자

ⓑ 형태소 분석기 : KoNLPy의 Okt( ) 사용

```
X_train = []
stopwords = ['의','가','이','은','들','는','좀','잘','걍','과','도','를','으로','자','에','와','한','하다'] # 불용어 지정
for sentence in tqdm(train_data['document']):
    tokenized_sentence = okt.morphs(sentence, stem=True) # 토큰화
    stopwords_removed_sentence = [word for word in tokenized_sentence if not word in stopwords] # 불용어 제거
    X_train.append(stopwords_removed_sentence)
```

```
tokenizer = Tokenizer()
tokenizer.fit_on_texts(X_train)
print(tokenizer.word_index)
```

```
{'영화': 1, '보다': 2, '을': 3, '없다': 4, '이다': 5, '있다': 6, '좋다': 7, '너무': 8, '다': 9, '정말':
```

Step 3. Data Preparation

④ Integer Encoding : 형태소 분석기로 분리한 텍스트를 정수로 바꾸기

ⓐ 텍스트를 단어 집합으로 만들기 → 각 단어 집합에 고유한 정수 부여하기 # 번호가 높을 수록 단어 등장 빈도수가 높음을 의미

```
threshold = 3
total_cnt = len(tokenizer.word_index) # 단어의 수
rare_cnt = 0 # 등장 빈도수가 threshold보다 작은 단어의 개수를 카운트
total_freq = 0 # 훈련 데이터의 전체 단어 빈도수 총 합
rare_freq = 0 # 등장 빈도수가 threshold보다 작은 단어의 등장 빈도수의 총 합

# 단어와 빈도수의 쌍(pair)을 key와 value로 받는다.
for key, value in tokenizer.word_counts.items():
    total_freq = total_freq + value

    # 단어의 등장 빈도수가 threshold보다 작으면
    if(value < threshold):
        rare_cnt = rare_cnt + 1
        rare_freq = rare_freq + value

print('단어 집합(vocabulary)의 크기 :',total_cnt)
print('등장 빈도가 %s번 이하인 희귀 단어의 수: %s'%(threshold - 1, rare_cnt))
print("단어 집합에서 희귀 단어의 비율:", (rare_cnt / total_cnt)*100)
print("전체 등장 빈도에서 희귀 단어 등장 빈도 비율:", (rare_freq / total_freq)*100)
```

```
단어 집합(vocabulary)의 크기 : 43752
등장 빈도가 2번 이하인 희귀 단어의 수: 24337
단어 집합에서 희귀 단어의 비율: 55.62488571950996
전체 등장 빈도에서 희귀 단어 등장 빈도 비율: 1.8715872104872904
```

Step 3. Data Preparation

④ Integer Encoding

ⓑ 등장 빈도수가 낮은 단어 집합 제거

```
# 전체 단어 개수 중 빈도수 2 이하인 단어는 제거.
# 0 번 패딩 토큰을 고려하여 + 1
vocab_size = total_cnt - rare_cnt + 1
```

ⓒ 텍스트 시퀀스를 숫자 시퀀스로 전환 : 텍스트에 생성한 정수 부여하기 # 0 번은 패딩을 위한 토큰

```
tokenizer = Tokenizer(vocab_size)
tokenizer.fit_on_texts(X_train)
X_train = tokenizer.texts_to_sequences(X_train)
X_test = tokenizer.texts_to_sequences(X_test)
```

ⓔ 빈 샘플 제거 : 삭제된 등장 빈도수가 낮은 단어는 빈 샘플이 됨 → 샘플의 길이를 확인하여 길이가 0 인 샘플 제거

```
drop_train = [index for index, sentence in enumerate(X_train) if len(sentence) < 1] # 샘플의 길이가 0 인 샘플들 가져오기
# 빈 샘플들을 제거
X_train = np.delete(X_train, drop_train, axis=0)
y_train = np.delete(y_train, drop_train, axis=0)
```

Step 3. Data Preparation

⑤ Padding : 샘플 길이 맞추기

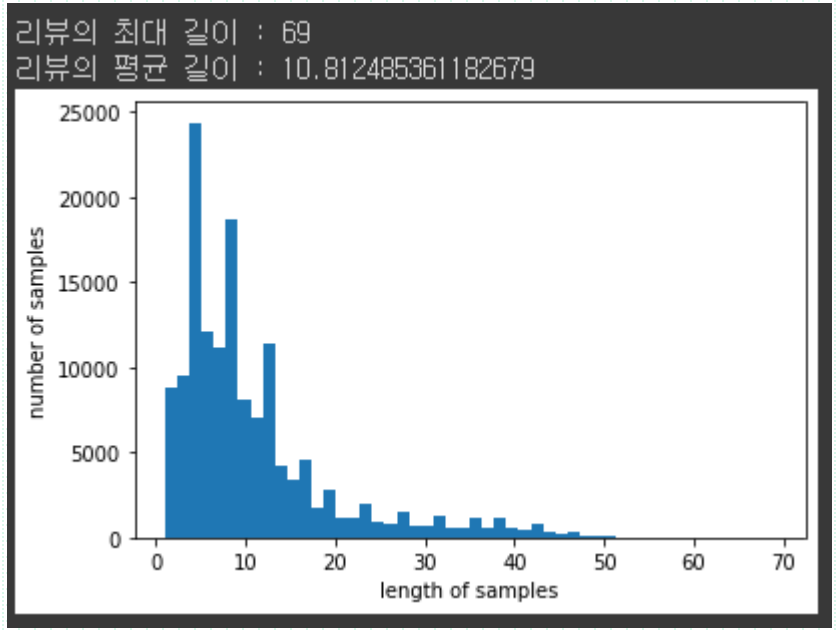

< 리뷰 데이터 길이 분포>

```
def below_threshold_len(max_len, nested_list):
  count = 0
  for sentence in nested_list:
    if(len(sentence) <= max_len):
        count = count + 1
  print('전체 샘플 중 길이가 %s 이하인 샘플의 비율: %s'%(max_len, (count / len(nested_list))*100))
```

ⓐ모든 샘플의 길이는 특정 길이(max_len)로 맞춰야 함 → 특정 길이 정하기

ⓑ 모든 샘플, 특정 길이로 맞추기

```
# 적절한 샘플 길이 찾기
def below_threshold_len(max_len, nested_list):
  count = 0
  for sentence in nested_list:
    if(len(sentence) <= max_len):
        count = count + 1
  print('전체 샘플 중 길이가 %s 이하인 샘플의 비율: %s'%(max_len, (count / len(nested_list))*100))

# 샘플 길이가 30인 경우
max_len = 30
below_threshold_len(max_len, X_train)
```

```
X_train = pad_sequences(X_train, maxlen = max_len)
X_test = pad_sequences(X_test, maxlen = max_len)
```

Step 4. Model Training

Step 4. Model Training

LSTM Model

- RNN의 hidden-state에 cell-state를 추가하여 장기 의존성 문제 해결
- RNN은 반복 모듈이 하나의 layer를 갖고 있으나, LSTM은 4개의 layer가 들어있다.

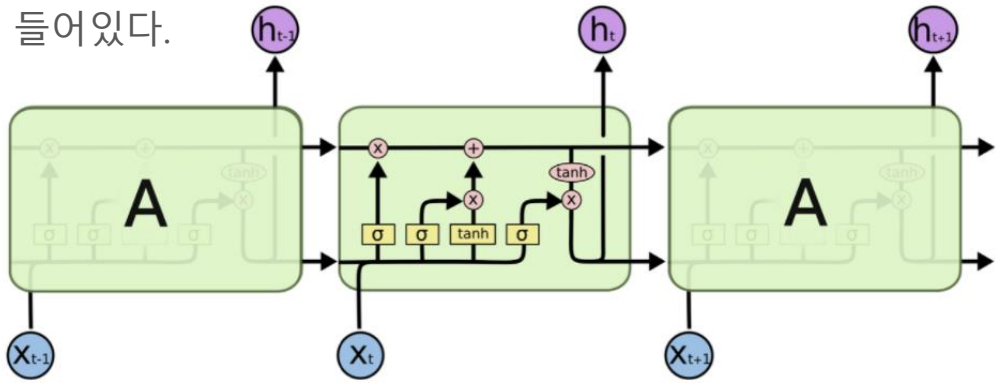

<LSTM Model>

① 모델 만들기

```
embedding_dim = 100
hidden_units = 128

model = Sequential()
model.add(Embedding(vocab_size, embedding_dim))
model.add(LSTM(hidden_units))
model.add(Dense(1, activation='sigmoid'))

es = EarlyStopping(monitor='val_loss', mode='min', verbose=1, patience=4)
mc = ModelCheckpoint('best_model.h5', monitor='val_acc', mode='max', verbose=1, save_best_only=True)

model.compile(optimizer='rmsprop', loss='binary_crossentropy', metrics=['acc'])
history = model.fit(X_train, y_train, epochs=15, callbacks=[es, mc], batch_size=64, validation_split=0.2)
```

② 모델 저장하기 : 해당 모델을 훗날 다시 사용할 수 있기에 저장해 준다.

```
%cd /content/
!pwd
!ls
model.save('best_model.h5')
```

Step 5. Model Qualification

Step 5. Model Qualification

① 정확도 측정

```
1 loaded_model = load_model('best_model.h5')
2 print("₩n 테스트 정확도: %.4f" %(loaded_model.evaluate(X_test, y_test)[1]))
```

```
527/1527 [==============================] - 9s 5ms/step - loss: 0.3471 - acc: 0.8536

테스트 정확도: 0.8536
```

' 정확도 : 0.85 '로 꽤 높음을 확인할 수 있다.

② 새로운 문장을 예측하는 함수 생성 – 함수 정확도 확인

```
2 def sentiment_predict(new_sentence):
3   new_sentence = re.sub(r'[^ㄱ-ㅎㅏ-ㅣ가-힣 ]','', new_sentence)
4   new_sentence = okt.morphs(new_sentence, stem=True) # 토큰화
5   new_sentence = [word for word in new_sentence if not word in stopwords] # 불용어 제거
6   encoded = tokenizer.texts_to_sequences([new_sentence]) # 정수 인코딩
7   pad_new = pad_sequences(encoded, maxlen = max_len) # 패딩
8   score = float(loaded_model.predict(pad_new)) # 예측
9   if(score > 0.5):
10    print("{:.2f}% 확률로 '긍정' 리뷰입니다.₩n".format(score * 100))
11  else:
12    print("{:.2f}% 확률로 '부정' 리뷰입니다.₩n".format((1 - score) * 100))
```

```
1 sentiment_predict('이게 영화인가')
```

```
94.61% 확률로 '부정' 리뷰입니다.
```

```
1 sentiment_predict('이것이 영화인가')
```

```
92.45% 확률로 '부정' 리뷰입니다.
```

그러나, 새로운 문장을 작성했을 때 '영화'와 관련된 문장임에도 불구하고 부정확한 판단한 것을 보아 'sample_data'한해서만 정확도가 높은 것임을 예상할 수 있다.

Step 5. Model Qualification

③ 데이터셋 손실 정도 그래프

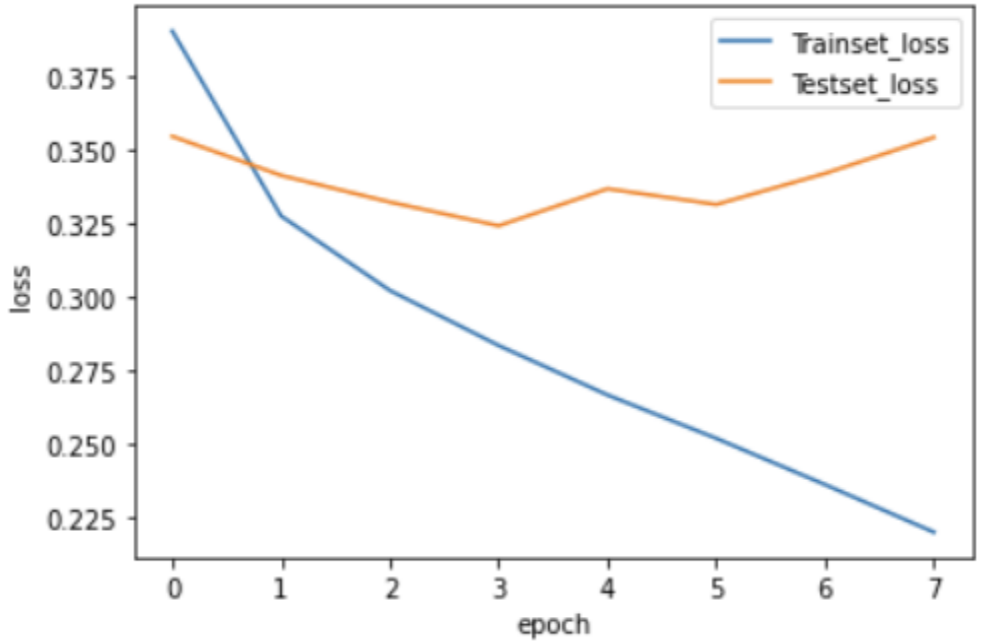

→ 반복 횟수가 증가할 수록 trainset의 손실은 감소하나, testset의 손실 변화는 적음을 볼 수 있다.

④ 반복 횟수 당 정확도 그래프

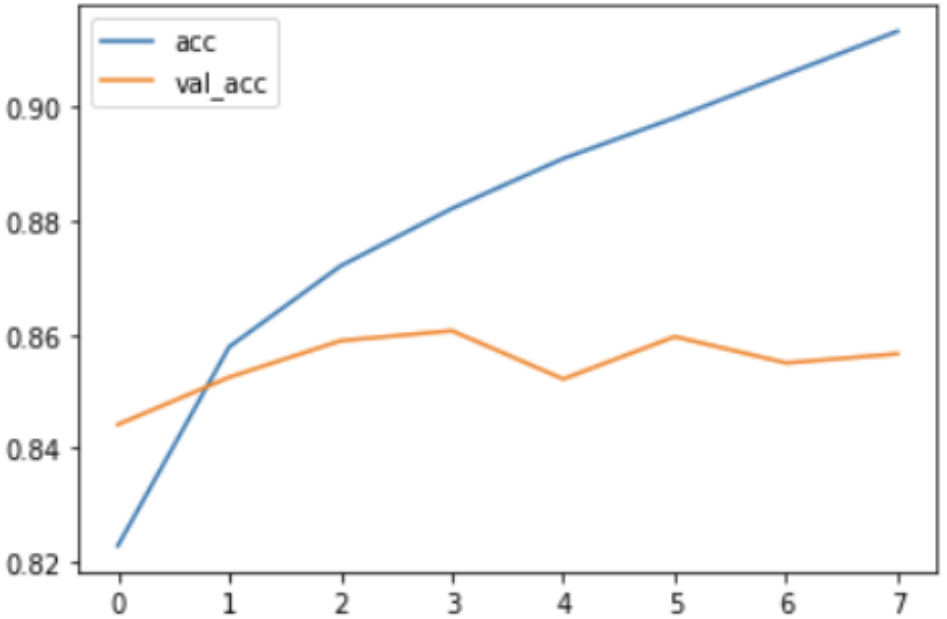

→ trainset의 반복을 15회로 지정했으나, 위 그래프를 통해 7회차 이상부터는 trainset와 testset의 반복 횟수 당 정확도 차이가 더 커지기에 7회차에서 멈추었음을 예상할 수 있다.

Step 6. Review Prediction

Step 6. Review Prediction

① Data Characteristics

```
# 필요한 모듈 불러오기
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt # 데이터 시각화 모듈

# 영화 이름 명시하기
print("영화 '%s' 분석을 시작합니다." %what_movie)

# 구글드라이브에서 현재 작업중인 코드로 데이터 불러오기
import pandas as pd
dataset = pd.read_csv(folder_path+'₩₩'+csv_name)

# 데이터셋의 정보를 파악한다
dataset.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 5517 entries, 0 to 5516
Data columns (total 7 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   Review Number    5517 non-null   int64
 1   Reviewer         5517 non-null   object
 2   Date             5517 non-null   object
 3   Reviewer Rating  5517 non-null   int64
 4   Review           5278 non-null   object
 5   Like             5517 non-null   int64
 6   Dislike          5517 non-null   int64
dtypes: int64(4), object(3)
memory usage: 301.8+ KB
```

ⓐ Review: 데이터 정제 → 토큰화 → 모델 적용

ⓑ Review Rating: ⓐ의 결과와 정확도 비교

② Data Preprocessing

```
df.drop(['Reviewer', 'Date','Like', 'Dislike'],axis=1,inplace=True) # 분석에 사용하지 않는 열 제거
df.drop_duplicates(subset=['Review'], inplace=True) # Review 열에서 중복인 내용이 있다면 중복 제거
df = df.dropna(how = 'any') # Null 값이 존재하는 행 제거
```

Step 6. Review Prediction

③ Predict Result

① 리뷰 평가(Result) : Cats 영화 리뷰를 best_model.h5 모델에 넣어 결과 예측

```
review_list = df.iloc[:,2] # Review 열만 추출
# 문장 예측해주는 함수
cat_list=[]
def sentiment_predict(new_sentence):
  new_sentence = re.sub(r'[^ㄱ-ㅎㅏ-ㅣ가-힣 ]','', new_sentence)
  new_sentence = okt.morphs(new_sentence, stem=True) # 토큰화
  new_sentence = [word for word in new_sentence if not word in stopwords] # 불용어 제거
  encoded = tokenizer.texts_to_sequences([new_sentence]) # 정수 인코딩
  pad_new = pad_sequences(encoded, maxlen = max_len) # 패딩
  score = float(loaded_model.predict(pad_new)) # 예측
  if(score > 0.5):
    cat_list.append("긍정")
  else:
    cat_list.append("부정")
# 예측 결과 for loop을 이용하여 cat_list 리스트에 담기
for i in review_list:
  sentiment_predict("%s" %i)
# 예측 결과를 Result 열로 만들어 기존의 DataFrame에 넣기
df['Result'] = cat_list
```

전처리

Result
긍정
긍정
긍정
부정
부정

② 생성한 새로운 DataFrame을 .csv 파일로 저장

```
df.drop(['Rating Result','Label'],axis=1)
df.to_csv('NaverMovie_Cats_ReviewResult_2021-12-08-10-37-20.csv',encoding='euc-kr')
```

.csv에 저장할 때 기본적으로 '한글'이 지원되지 않아 깨진 상태로 저장된다.
→ encoding = 'euc-kr'를 사용함으로써 한국어 저장에 지장이 없도록 한다.

Step 6. Review Prediction

④ Result Comparison

① 평점 평가(Rating Result) : Reviewer Rating을 긍정/부정으로 나누기

```
rating_list = df.iloc[:,1] # Reviewer Rating 열만 추출
# 결과 for loop을 이용하여 rating_result 리스트에 담기
rating_result = []
for i in rating_list:
  if i > 7:
    rating_result.append("긍정") # 평점 8점 이상은 긍정
  else:
    rating_result.append("부정") # 평점 7점 이하는 부정
# 결과를 Rating Result 열로 만들어 기존의 DataFrame에 넣기
df['Rating Result'] = rating_result
```

Rating Result
부정
부정
부정
부정
부정

- Review Rating > 7 : Like(긍정)
- Review Rating <= 7 : Dislike(부정)

② 결과 예측 값과 실제 결과(평점)을 for loop을 이용하여 긍정/부정이 일치하는지 확인

```
how_same = []
for x in range(0,len(df)):
  if cat_list[x] == rating_result[x]:
    how_same.append(0) # 같음을 의미 = 0
  else:
    how_same.append(1) # 일치하지 않음을 의미 = 1
# 일치 여부를 Label 열로 만들어 기존 DataFrame에 넣기
df['Label'] = how_same
```

Result	Rating Result	Label
긍정	부정	1
부정	부정	0
긍정	부정	1
부정	부정	0
부정	부정	0

As a Result ...

① Data Analysis Result

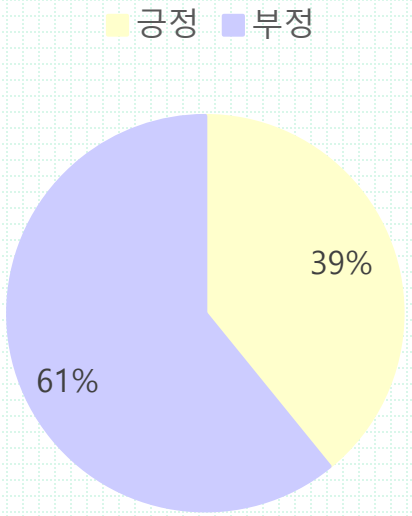

< 리뷰 평가 >

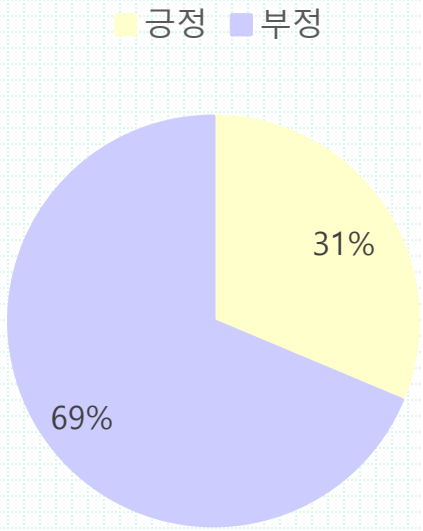

< 평점 평가 >

	리뷰 평가 (Result)	평점 평가 (Rating Result)
긍정	2026	1621
부정	3149	3554

→ 영화 ' Cats '에 대한 평가는 비교적 **부정적**임을 알 수 있다.

As a Result ...

② Match Rate

```
1 # Cats를 분석한 결과 일치율을 측정한다
2 num = (4272/len(df))*100
3 num = round(num,2)
4 print("Cats를 분석한 결과 해당 모델의 일치율은 %s입니다." %num)
```

```
Cats를 분석한 결과 해당 모델의 일치율은 82.55입니다.
```

기존 모델을 사용하여 Cats 리뷰를 분석한 결과, 모델을 이용한 리뷰 분석 결과와 실제 평점을 분석한 영화 선호도의 일치율은 "**82.55%**"이다. 따라서, Training-Test Data를 이용하여 만든 모델의 신뢰도는 비교적 높음을 예상할 수 있다.

< 일치율 >

" THANK YOU "